Santander Customer Transaction Prediction

Breitman, Zarina Madelaine
Marinella, Santiago
Navarro Quantín, Denise
Ramos, Mateo

Comisión 29780
Data Science

Profesor: Miguel Magaña Fuentes

Tabla de contenidos

1. Dataset y Objetivo

Origen del dataset: Kaggle

https://www.kaggle.com/datasets/lakshmi25npathi/santander-customer-transaction-prediction-dataset

Objetivo:

Predecir si se realizará una transacción determinada. Se eligió este dataset por recomendación del profesor debido a que tenía gran cantidad de entradas y es un dataset real.

2. EDA

Análisis del dataset

```
4 df = pd.read_csv('train.csv', index_col="ID_code")
5 df.head()
```

executed in 5.67s, finished 11:16:31 2022-10-28

ID_code	target	var_0	var_1	var_2	var_3	var_4	var_5	var_6	var_7
train_0	0	8.9255	-6.7863	11.9081	5.0930	11.4607	-9.2834	5.1187	18.6266
train_1	0	11.5006	-4.1473	13.8588	5.3890	12.3622	7.0433	5.6208	16.5338
train_2	0	8.6093	-2.7457	12.0805	7.8928	10.5825	-9.0837	6.9427	14.6155
train_3	0	11.0604	-2.1518	8.9522	7.1957	12.5846	-1.8361	5.8428	14.9250
train_4	0	9.8369	-1.4834	12.8746	6.6375	12.2772	2.4486	5.9405	19.2514

Variables con nombres desconocidos

```
1 df.shape
```

```
(200000, 201)
```

200.000 filas y 200 columnas

```
1 df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 200000 entries, train_0 to train_199999
Columns: 201 entries, target to var_199
dtypes: float64(200), int64(1)
memory usage: 308.2+ MB
```

Todas variables numéricas

2. EDA

Variable a predecir: **Target**

	Cantidad	Porcentaje
0	179902	90.0%
1	20098	10.0%

Variable target muy desbalanceada

```
1  J = df["target"].isna().sum()
2  print("Total null values in target column is " + str(J))
```

executed in 13ms, finished 11:17:12 2022-10-28

```
Total null values in target column is 0
```

Las otras variables:

Dataset limpio

```
1  df.isnull().any().value_counts()
```

```
False    201
dtype: int64
```

2. EDA

Las otras variables:

- Nula correlación entre variables
- Variables bastante simétricas

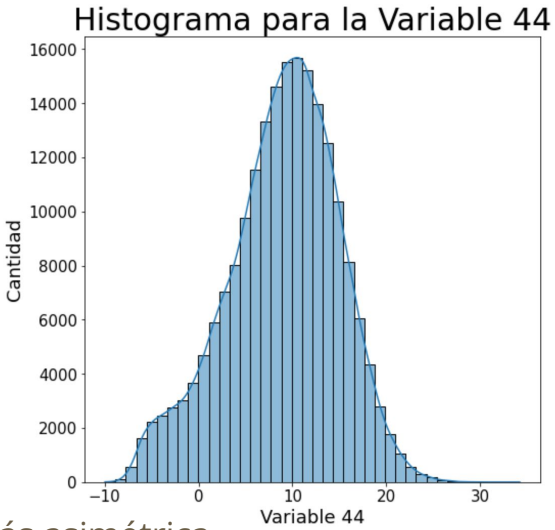

Variable más asimétrica

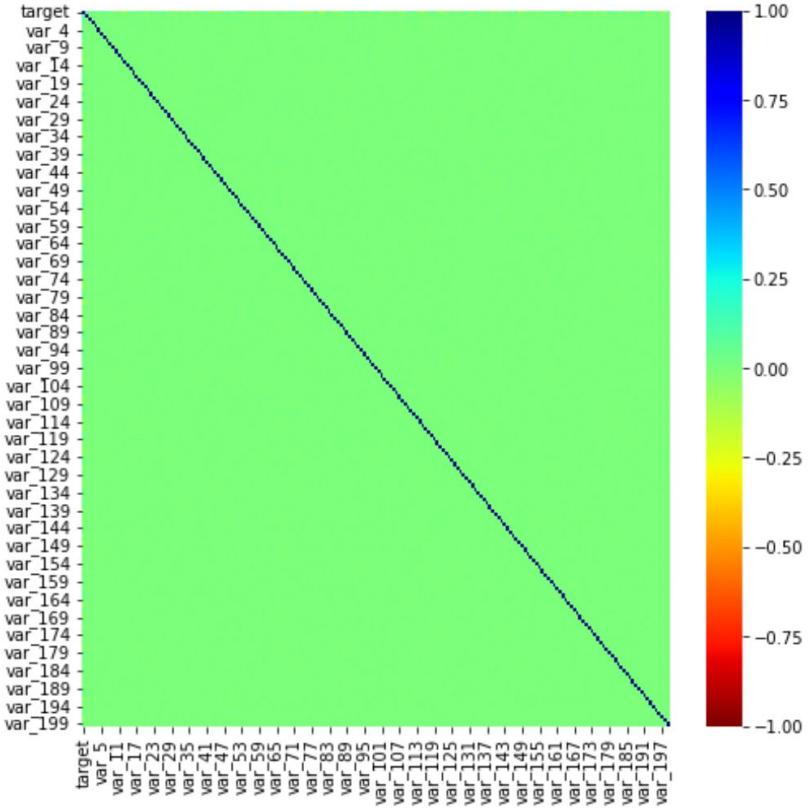

3. Modelos (Clasificación)

No boosting:

- LogisticRegression
- Naïve Bayes Classifier
- MLPClassifier (redes neuronales)
- K-Nearest Classifier (KNC)
- Support Vector Machine (SVC)
- Linear Discriminant Analysis (LDA)

Boosting:

- Randomforest
- Lightboost
- Adaboost
- Catboost
- XGB

3. Modelos (Métricas)

- Matriz de confusión
- Precision
- **Recall** (dataset desbalanceado)
- F1

$$\text{Precision} = \frac{True\ Positive}{True\ Positive + False\ Positive}$$

$$\text{Recall} = \frac{True\ Positive}{True\ Positive + False\ Negative}$$

Logistic Regression (all dataset)

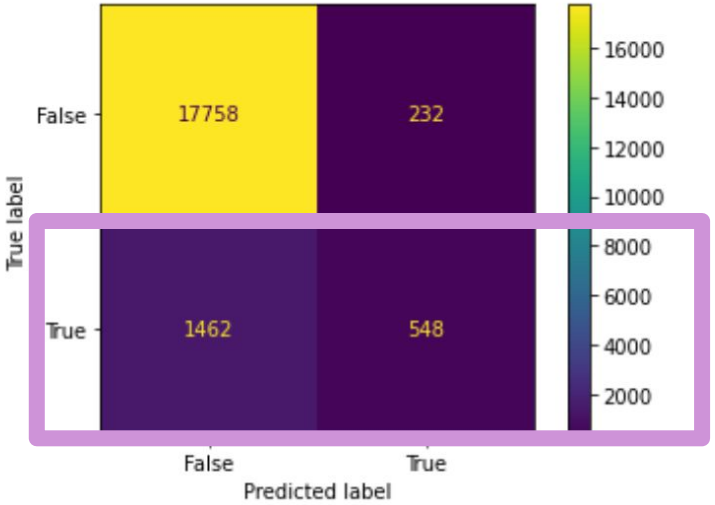


```
Precision score is 0.7025641025641025
Recall score is 0.272636815920398
F1 score is 0.392831541218638
```

https://towardsdatascience.com/accuracy-precision-recall-or-f1-331fb37c5cb9

3. Modelos

Metodología de trabajo

- Stratified K-fold
- PCA
  - 100 componentes
  - 125 componentes
  - 150 componentes
  - 175 componentes

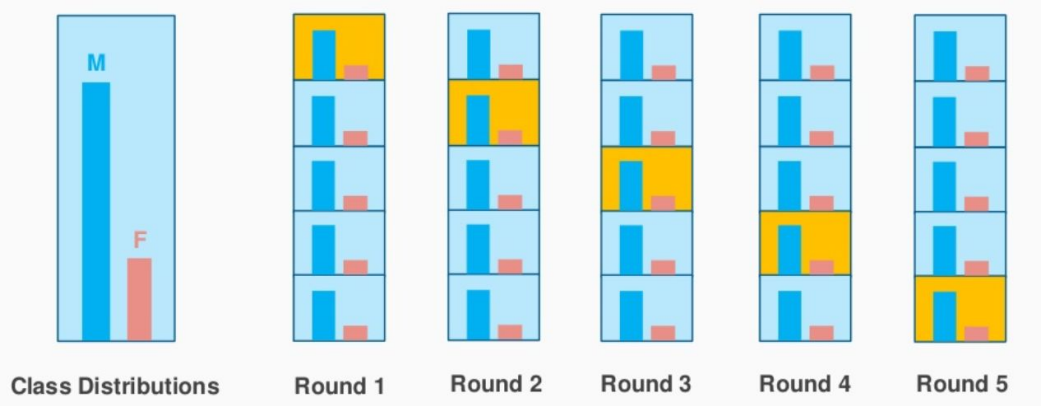


```
skf = StratifiedKFold(n_splits=10, shuffle= True, random_state= 1)
```

3. Modelos

Se obtuvo la media geométrica de cada modelo, promediando los resultados del Kfold.

Se evaluó el costo de cada algoritmo tomando el tiempo de ejecución total.

Elegimos a Logistic Regression como el modelo base.

	RECALL	Tiempo de ejecucion
Fulldata_Catboost	0.334661	501.352978
Fulldata_SVM	0.279937	10509.334164
Fulldata_LogisticRegression	0.268982	802.499365
Fulldata_XGBClassifier	0.249926	1023.306308
Catboost_170	0.242612	440.855039
LogisticRegression_185	0.232312	46.803771
LogisticRegression_170	0.209424	32.181545
XGBClassifier_170	0.189372	1040.673195
Catboost_130	0.187083	381.142504
XGBClassifier_130	0.159021	820.077986
SVM_170	0.149317	9863.222502
LogisticRegression_130	0.143547	29.909196
SVM_130	0.062743	9207.078305

4. Optimización de modelos

En modelos más costosos se optó por 10 a 20 trials
En modelos más livianos 150 a 400 trials

Se buscó maximizar el recall

Parámetros principales para boosts:

- **n_estimators**: cantidad de árboles en los bosques [300:3000]
- **max_depth**: profundidad de los árboles [3:21]
- **learning _rate**: tamaño de cada paso [0.25:0.85]

Parámetros para LogisticRegression:

- **max_iter**: número máximo de iteraciones para converger [7000:40000]
- **solver**: algoritmos de optimización del modelo ['newton-cg', 'lbfgs', 'liblinear', 'sag', 'saga']
- **penalty**: tipo de regularización del modelo ['l2', 'none'] para solvers ['sag', 'saga', 'lbfgs']

4. Optimización de modelos

Best parameters de los algoritmos.

MODEL	RECALL	OPTIMIZED RECALL	BEST PARAMETERS
Catboost_fulldata	0.3422	0.38396	-
Catboost_pca130	0.16733	0.25029	iterations = 3600, learning_rate = 0.85, depth = 4, logging_level = "Silent"
KNC_fulldata	0.003169	0.065738	'n_neighbors': 2, 'weights': 'distance', 'metric': 'minkowski'
KNC_175	0.003159	0.065937	'n_neighbors': 2, 'weights': 'distance', 'metric': 'minkowski'
GaussianNB	0.40502	–	No tiene parámetros para optimizar
Lightboost_175	0.05778	0.17344	'max_depth': 7, 'n_estimators': 510
Logistic Regression	0.269483	0.269483	‘max_iter’: 17689, ‘solver’: 'lbfgs'

La optimización de los parámetros de Logistic Regression no consiguieron mejorar el recall

5. Ensamble de modelos

Voting Classifier

Se validaron diferentes ensambles de modelos con esta metodología. El mejor resultado para el recall fue inferior a los modelos sin ensamble y el costo computacional, mayor.

StackingClassifier

Se obtuvieron resultados sustancialmente mejores comparados con los modelos sin ensamblar.
El recall alcanzó una mejora aproximada de un 134%.

5. Ensamble de modelos

StackingClassifier

Se probaron diversas combinaciones de modelos. Estos son los modelos con mayor recall.

- GaussianNB x6 + final GaussianNB
- GaussianNB x12 + final GaussianNB
- GaussianNB x24 + final GaussianNB
- GaussianNB + Linear Discriminant Analysis + final GaussianNB
- GaussianNB x24 + Linear Discriminant Analysis + final GaussianNB
- GaussianNB x12 + Logistic Regression + Linear Discriminant Analysis + final GaussianNB

5. Ensamble de modelos

GaussianNB x24 + Linear Discriminant Analysis + final GaussianNB

GaussianNB x6 + final GaussianNB

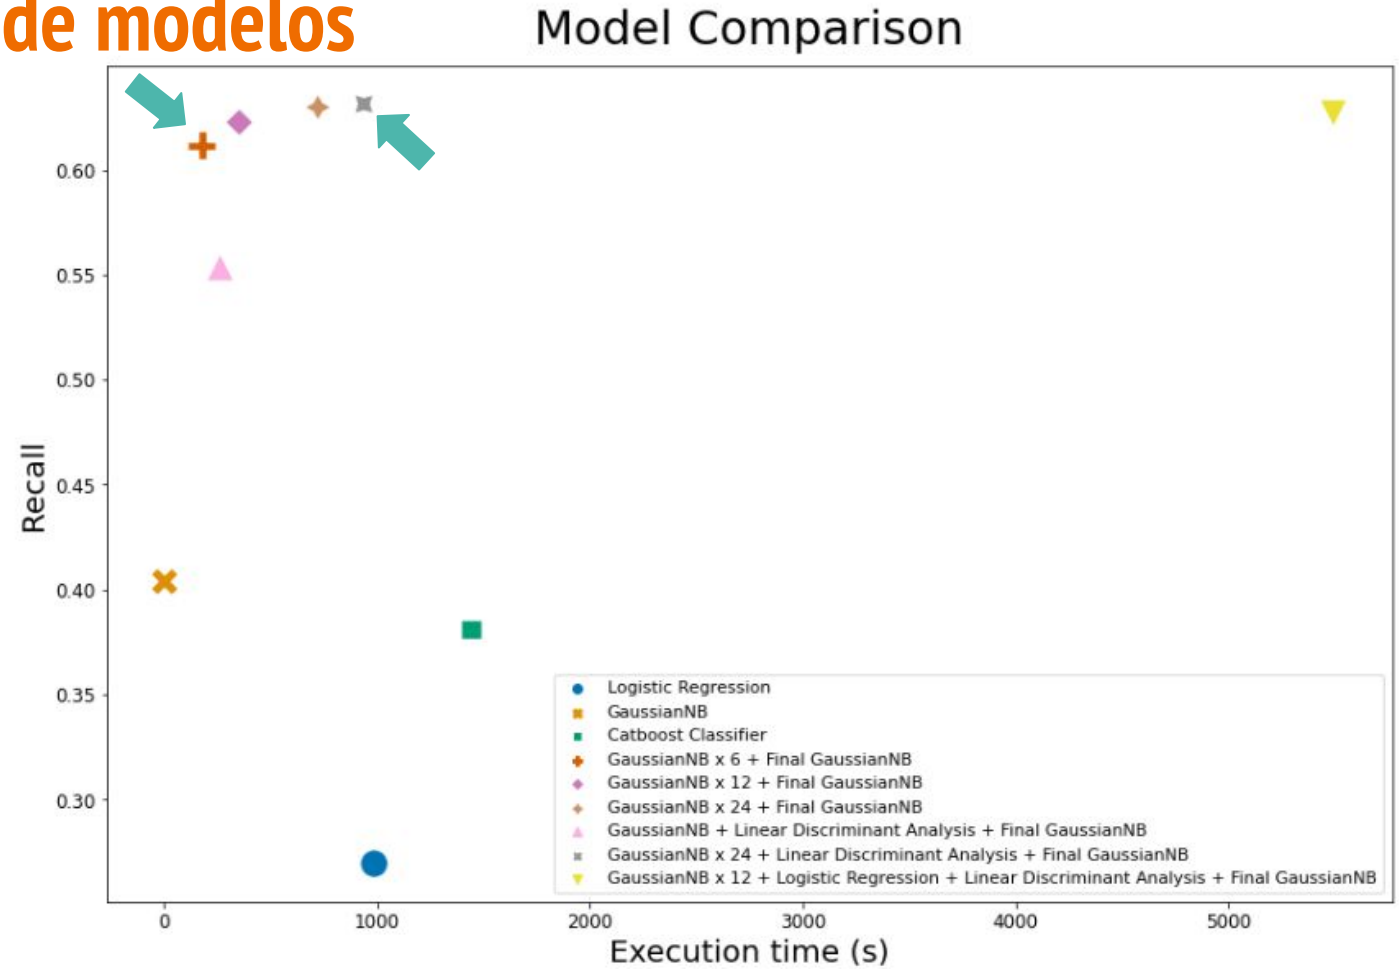

6. Conclusión

El modelo base con el que se comenzó el proyecto es la Regresión Logística con un Recall de 0.269483 y un tiempo de ejecución de 988.74 segundos.

El modelo de ensamble que mejor identificó si se harán o no transacciones, es GaussianNB x 24 + Linear Discriminant Analysis + Final Estimator GaussianNB que obtuvo un recall de 0.631196 con un tiempo de ejecución de 940.58 segundos. Es decir, un incremento de 134% de la métrica recall en comparación con el modelo base y una disminución del 5% del tiempo de ejecución.

Sin embargo, GaussianNB x 6 + Final Estimator GaussianNB obtuvo un recall solamente 3% inferior al modelo de ensamblado anterior, 0.611569 con un tiempo de ejecución de 178.87 segundos. Dicho de otro modo, 500% más veloz y en consecuencia con un menor costo computacional.

6. Conclusión

En vista de esta situación dividimos nuestra recomendación en dos:

Si se desea realizar la mayor cantidad de detecciones, sin importar el costo computacional, utilizar el primer ensamblado sería lo correcto. Sin embargo, observando el costo computacional, consideramos más conveniente emplear GaussianNB x 6 + Final Estimator GaussianNB como modelo final.

El análisis realizado con el set de datos obtenido, nos ha permitido crear un modelo de ensamblado que prediga de manera correcta un poco más del 60% de las transacciones. Lo que representa una mejora de aciertos, superior al 125% que utilizando un único modelo individual, 6842 más aciertos para este set de datos.

Esta búsqueda podría continuar si se contara con mayor poder de procesamiento para realizar optimizaciones más robustas o mismo evaluar modelos más complejos.

Consideramos haber realizado un buen análisis de la problemática planteada, que es posible mejorar aún más a futuro.